HELLO,

I ‘M

LEE SEUNGYOON

seoungyoon14@gmail.com

2026-10-15

ABOUT ME



안녕하세요, 이승윤입니다.

- Human-Centered AI @ Sangmyung Univ(2023 ~ present)
- Interested in LLM Evaluation, RAG, and NLP
- Experience in RAG development, LLM evaluation, and ML research
- Seeking to grow as an LLM/NLP researcher

My main interest is understanding how to systematically evaluate and improve LLM systems.

- github
- linkedin
- personal blog

SKILLS

PROGRAMMING LANGUAGES

Python, C, C#, SQL, TypeScrip

MACHINE LEARNING/AI

scikit-learn, XGBoost, LightGBM, Reinforcement Learning, Unity ML-Agents, LLM Evaluation, Model Quantization

TOOLS & ENGINEERING

Git, GitHub, GitHub Actions, Firebase, React Native, Unity



PROJECT

- PROJECT 01 - Turini (PBL)
- PROJECT 02 - Penalty RL(Unity)
- PROJECT 03 - Research experience

PROJECT 01 – TURINI (PBL)



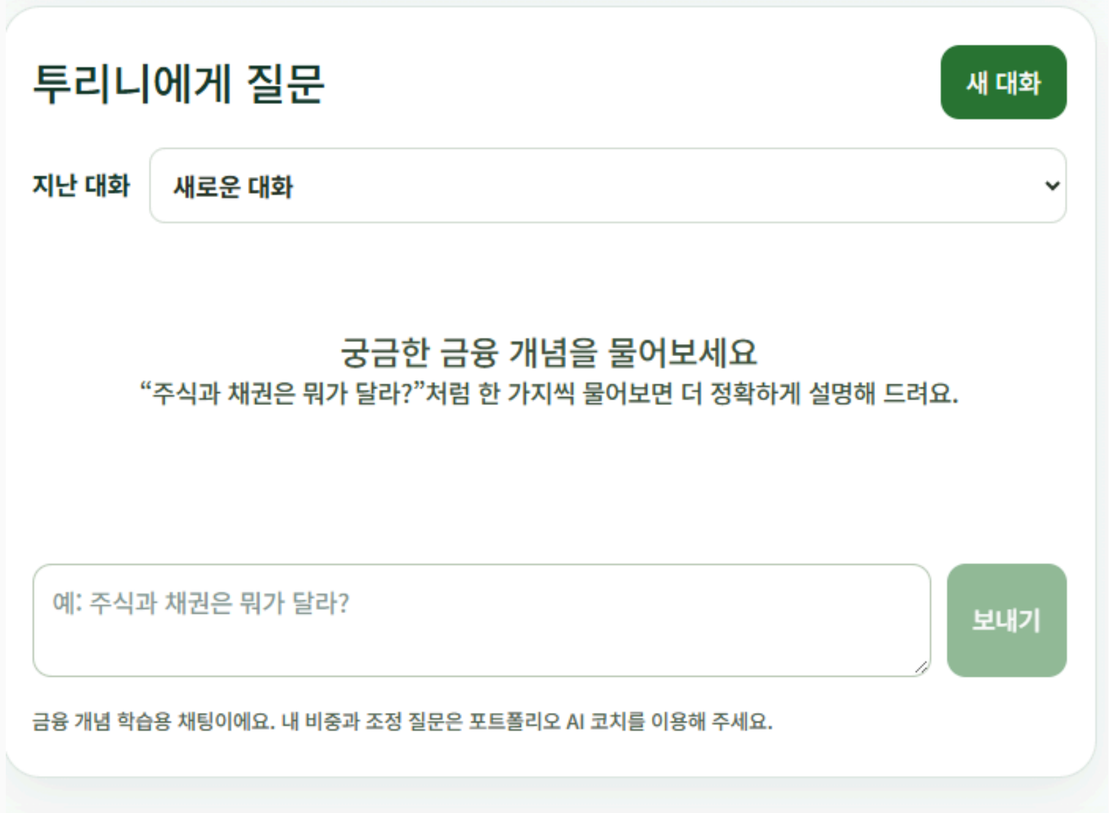
ABOUT TURINI

Turini는 금융·투자 입문자가 자신의 **금융 수준(Level), 투자 스타일(Style), 투자 성향(Personality)**을 진단하고, 그 결과를 바탕으로 본인에게 필요한 금융 개념부터 학습할 수 있도록 돕는 맞춤형 금융 교육 앱입니다.
사용자는 진단 결과를 통해 자신의 성향과 취약 영역을 확인하고, 레벨별 퀴즈와 추천 학습 순서를 따라 금융 지식을 체계적으로 보완할 수 있으며, 직접 입력한 포트폴리오에 대해서도 매수·매도 추천이 아닌 적합도, 리스크, 보완이 필요한 개념 중심의 교육형 해설을 받을 수 있습니다.

즉, Turini는 단순한 투자 정보 제공이나 거래 앱이 아니라, 진단 → 이해 → 학습 → 포트폴리오 탐색의 흐름을 통해 사용자가 스스로 금융 판단력을 키우도록 돕는 개인화 금융 학습 서비스입니다.

Turini github

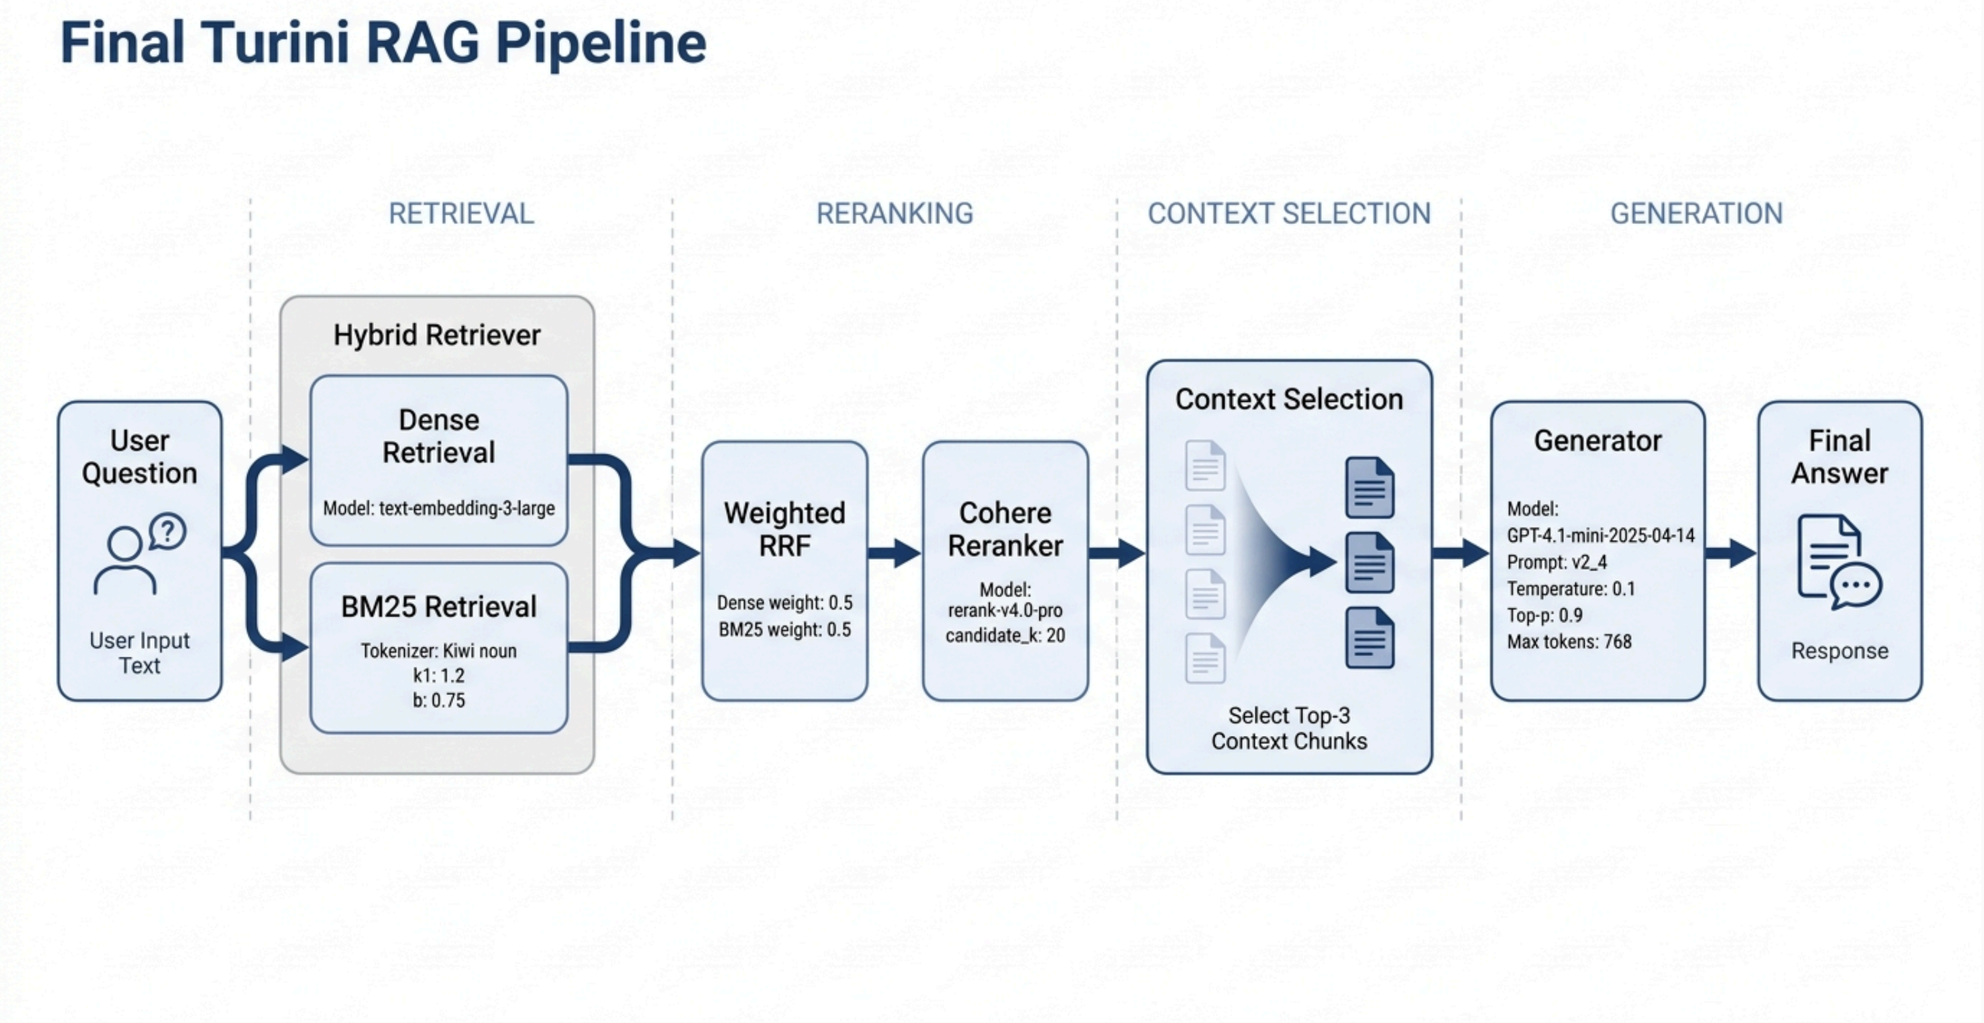
PROJECT 01 – TURINI (PBL)



HOW WE APPLIED RAG

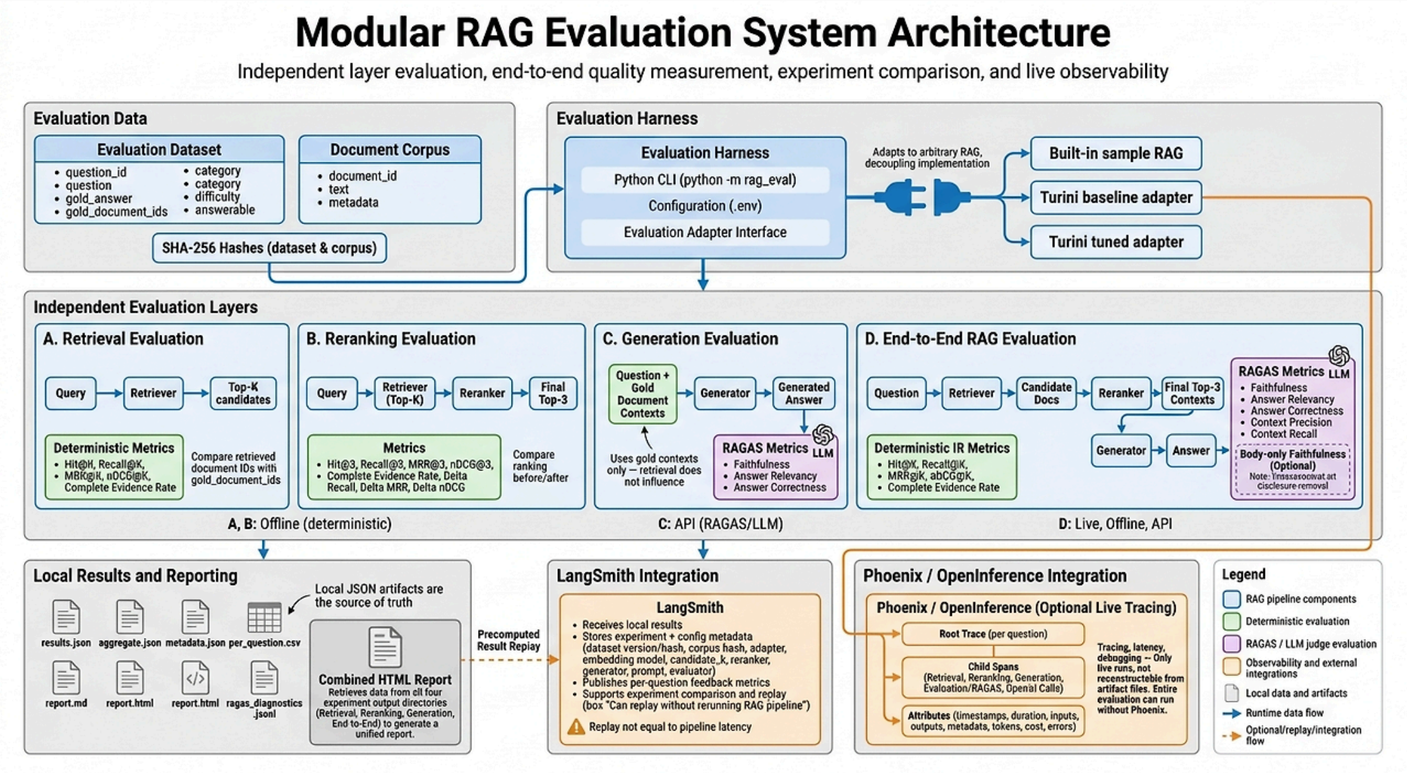
Turini는 복잡한 금융 정보를 사용자가 이해하기 쉬운 형태로 설명하고 사용자가 금융 개념이나 투자 상품에 대해 질문하면 Query Rewrite를 통해 문맥을 반영한 독립적인 검색 질문으로 변환하고, Dense Retrieval·BM25·Hybrid Retrieval·Reranking 기반 RAG 파이프라인을 통해 신뢰할 수 있는 금융 데이터를 검색한 뒤 근거 중심의 답변을 제공합니다. 특히 단순한 일회성 Q&A가 아니라 “그럼 둘의 차이는?”, “내 포트폴리오에서는 어떤 의미야?”와 같은 후속 질문까지 자연스럽게 이해하며, 향후 사용자의 포트폴리오 정보와 결합해 개인화된 금융 해설까지 제공하는 것을 목표로 합니다.

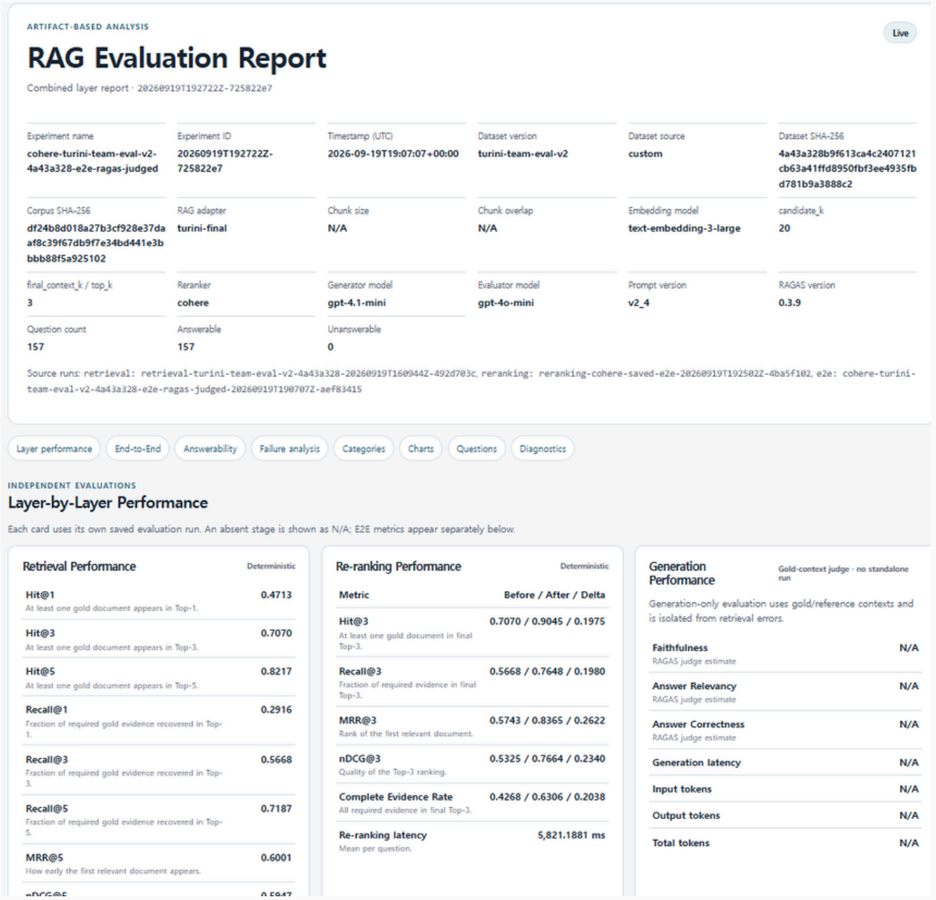
PROJECT 01 – TURINI (PBL)



PROJECT 01 – TURINI (PBL)

EXTENDING RAG WITH RELIABLE EVALUATION





PROJECT 01 – TURINI (PBL)

THE PROBLEM WE ENCOUNTERED



Full text

RAGAS judge estimates

Faithfulness	0.7058
Answer Relevancy	0.3270
Answer Correctness	0.5839
Context Precision	0.9968
Context Recall	0.8899

그래서 내린 결론

이번 문제를 겪으면서 가장 크게 바뀐 생각은 하나다.

RAG 평가에서 특정 하나의 Metric에 너무 목맬 필요는 없다.

물론 Answer Relevancy는 중요한 지표다. 질문에 제대로 대답하지 않는 RAG라면 아무리 Faithfulness가 높아도 좋은 시스템이라고 하기 어렵기 때문이다.

하지만 Answer Relevancy 하나가 낮다는 이유만으로 전체 RAG의 성능이 낮다고 판단하는 것도 위험하다.

결국 RAG 평가에서는 여러 평가 축을 동시에 볼 필요가 있다.

예를 들어 Retrieval 단계에서는 Hit@K, Recall@K, MRR, nDCG 등을 통해 필요한 문서를 제대로 검색했는지를 확인할 수 있다.

Generation 단계에서는 Faithfulness, Answer Relevancy, Answer Correctness 등을 통해 생성된 답변의 품질을 확인할 수 있다.

그리고 마지막으로 Human Evaluation을 통해 사람이 실제로 답변을 읽었을 때 관련성, 정확성, 유용성이 충분한지 확인해야 한다.

결국 내가 현재 생각하는 RAG 평가는 다음 세 가지를 함께 보는 형태에 가깝다.

Retrieval Metrics + Generation Metrics + Human Evaluation

그리고 이 세 결과가 서로 일치하지 않는다면 그것을 단순히 "평가가 이상하다"고 넘기는 것이 아니라,

왜 특정 Metric만 다른 방향을 가리키는지 자체를 분석해야 한다.

오히려 그 불일치가 RAG 시스템의 문제일 수도 있고, 자동 평가 Metric의 한계일 수도 있기 때문이다.

PROJECT 01 – TURINI (PBL)

LLM-as-a-Judge for Low-Resource Languages: Adapting Ragas and Comparative Ranking for Romanian

Claudiu Creanga[2,3], **Liviu P. Dinu**[1,3]
[1] Faculty of Mathematics and Computer Science,
[2] Interdisciplinary School of Doctoral Studies,
[3] HLT Research Center,
University of Bucharest, Romania
claudiu.creanga@fmi.unibuc.ro, ldinu@fmi.unibuc.ro

Ragas: Automated Evaluation of Retrieval Augmented Generation

Shahul Es[†], **Jithin James**[†], **Luis Espinosa-Anke**[*◇], **Steven Schockaert**[*]
[†]Exploding Gradients
[*]CardiffNLP, Cardiff University, United Kingdom
[◇]AMPLYFI, United Kingdom
shahules786@gmail.com, jamesjithin97@gmail.com
{espinosa-ankel, schockaerts1}@cardiff.ac.uk

I started by building AI systems, but became increasingly interested in how to evaluate whether they actually work reliably.

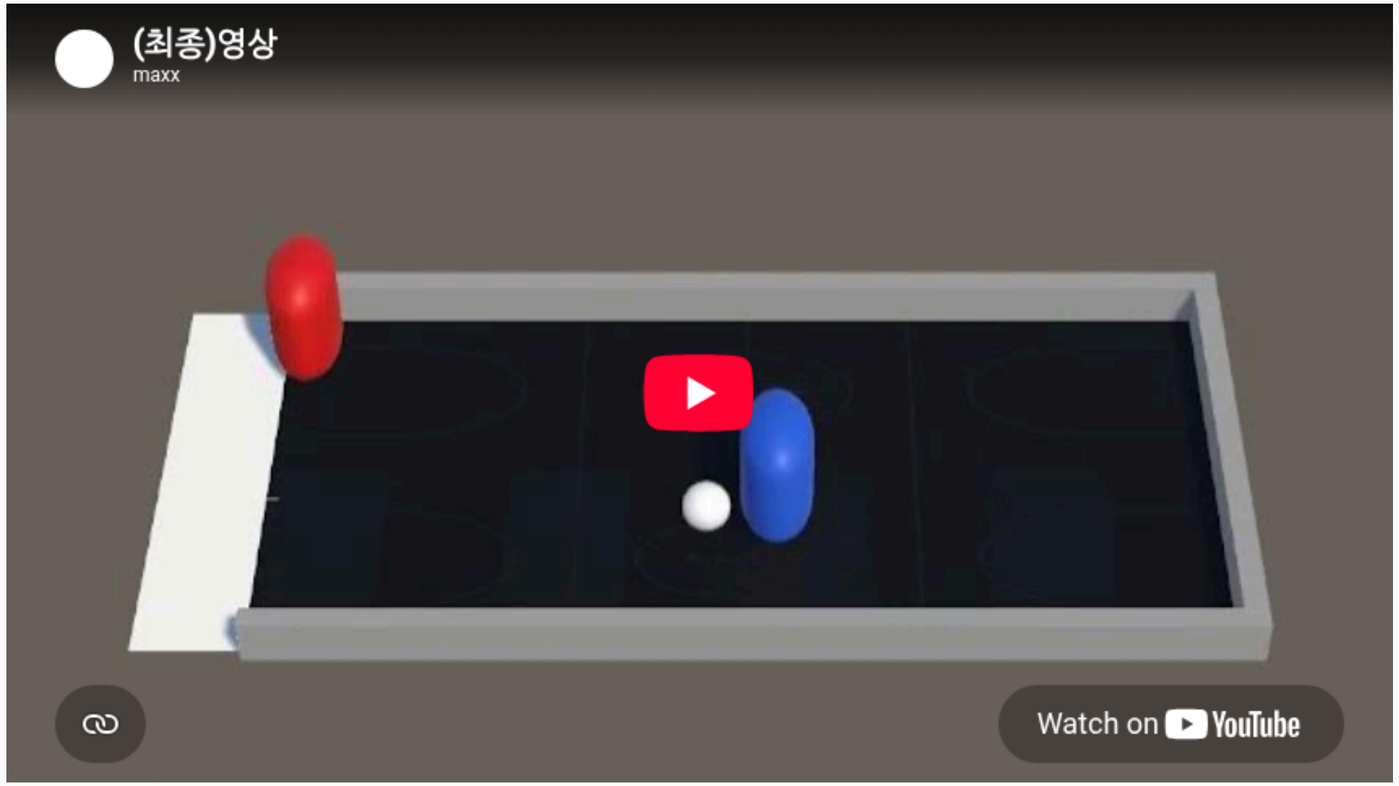
PROJECT

PROJECT 01 - Turini (PBL)

PROJECT 02 - Penalty RL(Unity)

PROJECT 03 - Research experience

PROJECT 02 - PENALTY RL(UNITY ML-AGENTS)



Built a penalty-kick environment using Unity ML-Agents, where agents learned optimal actions through reinforcement learning.

github

PROJECT 02 – PENALTY RL(UNITY ML-AGENTS)

WHAT MADE OUR PROJECT STAND OUT

개발 과정 – 시행착오 (1차/ 2차)

문제점:
학습 자체가 되지 않았음
보상이 없음 → 정책 업데이트 불가
Kicker가 공에 접근조차 못함
양쪽 에이전트 모두 의미 없는 탐색 반복

해결시도:
Kicker에게 공이 닿을때 &공과의 거리를 좁힐수록 보상
Goal keeper와 이 닿을때 보상

→ 경기장 밖으로 나가는 문제는 해결이 됨

문제점:
아직 학습이 잘 안되는 걸로 보임
국소해 고립 문제 보임

해결 시도:
PPO 하이퍼파라미터(탐색)를 강화
•Entropy 계수 증가
•Epsilon 증가 → 정책 업데이트 폭 증가
•buffer size/batch size 증가 → 안정성 향상
•Learning rate 조절

→ 하이퍼파라미터 값보다 MDP&환경 완성이 우선

개발 과정 – 시행착오 (3차 /4차)

문제점:
환경 전면 개편

해결시도:
에이전트/골대/속도/행동 범위 등 전체 환경 개선

→ 여전히 국소해 문제가 남아있음

문제점:
에이전트들의 여전한 국소해 문제

해결시도:
Goal Keeper 보상 강화 Goal Keeper는 빠르게 강해짐
공의 y축 움직임 추가했지만 삭제
보상 불균형 + 물리 설정 오류로 실패

→ Kicker는 계속 패배 → 보상 음수
→ 정책 collapse
보상 불균형 + 물리 설정 오류로 실패

개발 과정 – 시행착오 (5차)

문제점:
4차에 이어
여전히 국소 해 문제
학습이 안되는 거처럼 보임

해결시도:
Goal Keeper의 보상 값을 제한 등등 여러가지 reward shaping 시도

→ **Kicker 행동이 눈에 띄게 개선됨**
•초기 10회 테스트 기준:
- 1번 골 성공
- 5번 유효슈팅 중 4번은 공 접촉 실패
- 하지만 **명확하게 공을 향해 붙는 움직임 증가**
- 시간이 지날수록 **정면 슈팅 시도도 나타남**
  → 이전(4차)에는 아예 슈팅 시도조차 없었던 것과 대비됨

Keeper는 정상적인 방어 행동을 학습
•유효슈팅 4번 전부 방어 성공
•10번 중 단 1번만 실점
•Keeper의 움직임이 "공 중심 라인 따라가기" 방향으로 안정화됨

하지만 에피소드가 지날수록 여전히 국소 해 문제가 나타남

PROJECT 02 – PENALTY RL(UNITY ML-AGENTS)

WHAT MADE OUR PROJECT STAND OUT



- Recorded changes in state, action, and reward design
- Compared different training settings
- Analyzed failures instead of only showing successful results
- Presented why certain approaches worked or failed



PROJECT

PROJECT 01 - Turini (PBL)

PROJECT 02 - Penalty RL(Unity)

PROJECT 03 - Research experience

PROJECT 03 – RESEARCH EXPERIENCE(MANUSCRIPT SUBMITTED)

MESA 액티그래피 자료에서 수면시간의 일별 변동성과 주간 졸림의 관련성

이승윤1, 이의철2*
1상명대학교 휴먼지능정보공학과 학생, 2상명대학교 휴먼지능정보공학과 교수

Association of Night-to-Night Sleep Duration Variability With Daytime Sleepiness in MESA Actigraphy Data

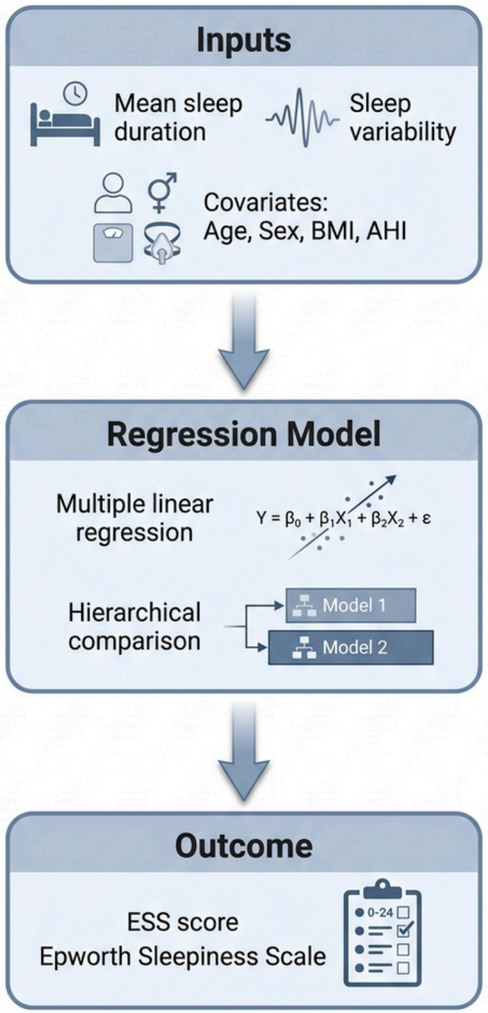
Seung-Yoon Lee1, Eui Chul Lee2*
1Student, Department of Human-Centered Artificial Intelligence, Sangmyung University
2Professor, Department of Human-Centered Artificial Intelligence, Sangmyung University

요 약 본 연구는 평균 수면수준을 고려한 이후에도 일별 수면 변동성이 주간 졸림과 관련되는지를 확인하고자 하였다. MESA Sleep Study의 30초 단위 손목 액티그래피 원자료에서 일별 수면시간, 수면효율, wake after sleep onset(WASO), sleep midpoint를 산출하고 연속 7일의 개인 내 표준편차를 계산하였다. 최종 1,527명을 대상으로 Epworth Sleepiness Scale(ESS)을 종속변수로 한 OLS 회귀분석에 HC3 robust standard error를 적용하였다. 각 지표의 평균수준, 나이, 성별, BMI, AHI를 보정한 개별 모델에서 수면시간 SD, WASO SD, sleep midpoint circular SD가 ESS와 유의한 양의 관련성을 보였고 FDR 보정 후에도 유지되었다. 모든 변동성 지표를 동시에 포함한 joint model에서는 수면시간 SD만 유의한 관련성을 유지하였다(standardized β=0.0759, p=0.0149). 수면시간 SD 추가에 따른 ΔR^2는 0.00488이었다. 평균 수면시간을 고려한 이후에도 수면시간의 일별 변동성은 주간 졸림과 작지만 일관된 관련성을 보였다.

Does sleep variability predict daytime sleepiness beyond average sleep duration?

- **Dataset: MESA Sleep**
- **Outcome: Epworth Sleepiness Scale (ESS)**
- **Focus: Sleep duration / efficiency / WASO / midpoint variability**

PROJECT 03 – RESEARCH EXPERIENCE (MANUSCRIPT SUBMITTED)



- **selected participants with sufficient valid nights**
- **calculated SD / CV for sleep metrics**
- **controlled for age, sex, BMI, AHI**
- **compared mean-only vs mean + variability models**

→ **Sleep duration variability showed a small but consistent association with daytime sleepiness beyond average sleep duration, but the findings should be interpreted cautiously.**

WHY THIS LAB / WHAT I WANT TO EXPLORE

1. My Experience Led Me to Evaluation

Through building RAG systems, I became interested not only in improving performance, but in whether the evaluation itself truly reflects system quality.

2. Strong Alignment with the Lab

I was especially interested in the lab's work on realistic and constraint-aware evaluation, such as MindVoyager and PAC-BENCH.





WHY THIS LAB / WHAT I WANT TO EXPLORE

3. From RAG Evaluation to Agent Evaluation

I want to extend my experience from retrieval and generation evaluation toward LLM agents, long-horizon interaction, reliability, and evaluation under realistic constraints.

4. What I Hope to Become

I want to grow from someone who builds AI systems into a researcher who can design meaningful evaluation settings, analyze failure modes, and improve reliable LLM systems.

THANK YOU!